



DETECCIÓN DE CAMBIOS EN INTERFACES WEB PARA PROCESOS RPA UTILIZANDO INTELIGENCIA ARTIFICIAL

OBJETIVO

Este reporte analiza entrenamientos con YOLOv8 en interfaces web, evaluando métricas para detectar underfitting y overfitting. Se establecieron modelos base y un sistema de seguimiento para registrar resultados de forma persistente.

METODOLOGÍA

Se aplicó una metodología experimental iterativa y comparativa, empleando las variantes YOLOv8n, YOLOv8m y YOLOv8l, con ajustes de hiperparámetros y dataset para optimizar el rendimiento, y se evaluaron métricas clave como precisión, recall, F1-score y mAP para analizar la efectividad del modelo.

ANÁLISIS DE RESULTADOS

Los resultados de los entrenamientos 5 al 8, se detallan por ser los que mostraron mejores resultados. Todos usaron el modelo YOLOv8l con las siguientes configuraciones:

- **Entrenamiento 5:** Dataset original, data augmentation limitado a color y brillo, learning rate inicial alto.
- **Entrenamiento 6:** Mismo dataset, reducción de learning rate y ajustes en data augmentation para mayor estabilidad.
- **Entrenamiento 7:** Ajuste de hiperparámetros: scheduler coseno, aumento de weight decay, early stopping activado.
- **Entrenamiento 8:** Dataset reducido a 3 clases, mismos hiperparámetros que en entrenamiento 7.

Entrenamiento/Experimento	Precision	Recall	F1-score
1 - YOLOv8n + Dataset Original	0.4194	0.1391	0.2089
2 - YOLOv8n + Dataset Balanceado	0.2999	0.1348	0.1860
3 - YOLOv8n + Dataset Estratificado	0.3046	0.1407	0.1925
4 - YOLOv8m + Dataset Original	0.6155	0.1969	0.2983
5 - YOLOv8l + Ajuste 1	0.8117	0.2595	0.3933
6 - YOLOv8l + Ajuste 2	0.7730	0.2632	0.3927
7 - YOLOv8l + Ajuste 3	0.8357	0.2728	0.4114
8 - YOLOv8l + Reducido (3 clases)	0.7454	0.5039	0.6013

El modelo del **Entrenamiento #7** es el más equilibrado para producción general: logra el mejor **F1-score (0.41)** con buena precisión en clases frecuentes, gracias a ajustes en regularización y pérdida.

El modelo del **Entrenamiento #8** es ideal como **MVP**: detecta solo 3 clases (input, button, link) pero con alta consistencia, logrando **F1-score de 0.60** y **recall de 0.50**.

Tutora: PhD. Gladys M. Villegas Rugel
Autores: Andrés M. Cantos Rivadeneira- María P. Mendoza Mendieta



ESTRATEGIAS

RESULTADOS

Balanceo del dataset

- Aumento leve en el recall general.
- No se superó el rendimiento del dataset original con modelos más robustos.
- Clases minoritarias no mejoraron significativamente.

Ajuste de hiperparámetros

- Mejora en precisión sin sobreajuste.
- YOLOv8l ajustado alcanzó Precisión 0.8357, Recall 0.2728, F1-score 0.4114.


Data augmentation seguro

- Conservación de la semántica visual de los elementos.
- Mejora en generalización sin afectar precisión en clases estructurales.

Escalado de modelo (YOLOv8n→l)

- Mejora consistente en precisión y mAP50.
- Mayor capacidad de generalización y menor pérdida en validación.

ANÁLISIS DE APRENDIZAJE



El gráfico muestra la evolución del gap de Box Loss para los experimentos 1, 6 y 7. El Exp1 presenta underfitting con pérdida alta y aprendizaje limitado, mientras que los Exp6 y 7 corrigen el subajuste pero muestran algo de overfitting, siendo el Exp7 el que mejor equilibra baja pérdida y generalización. Esto refleja la mejora progresiva del modelo en capacidad de localización y estabilidad.

CONCLUSIÓN Y RECOMENDACIÓN

Los entrenamientos realizados con el modelo YOLOv8l, a partir del entrenamiento 5, demuestran que el escalado del modelo, junto con ajustes cuidadosos en hiperparámetros y data augmentation segura, generan mejoras significativas en precisión y capacidad de generalización, mostrando ausencia de overfitting y reducción del underfitting.

Se recomienda usar la configuración del Exp7 con post-procesamiento durante la inferencia si se prioriza la precisión, mientras que, para maximizar la cobertura o recall, conviene optar por el entrenamiento Exp8 con un dataset reducido.

Repositorio GitHub: [Codigo fuente de 8 entrenamientos YOLOv8](#)

Fuente: Redmon, J. et al. (2016). "You Only Look Once: Unified, Real-Time Object Detection". Ultralytics YOLOv8 Documentation.